

Prosedürel Oyun Seviyesi Üretimi: Derin Öğrenme ve Kural Tabanlı Yaklaşımların Karşılaştırılması

Procedural Game Level Generation: A Comparison of Deep Learning and Rule-Based Approaches

Moussa BANE

BURSA TEKNİK ÜNİVERSİTESİ

BİLGİSAYAR MÜHENDİSLİĞİ

YÜKSEK LİSANS (TEZLİ)

Bursa, Türkiye

banemoussa2001@gmail.com

<https://github.com/MoussaBane/BOYZ-Procedural-Game-Level>

Öz—Bu çalışma, derin öğrenme tekniklerinin oyun seviyelerini prosedürel olarak üretme potansiyelini kapsamlı bir şekilde incelemektedir. Oyun tasarımı, oyuncu deneyimini zenginleştirmek ve içerik çeşitliliğini artırmak amacıyla prosedürel üretim yöntemleri giderek daha fazla önem kazanmaktadır. Bu bağlamda, özellikle Generative Adversarial Networks (GAN'ler) ve autoencoder'lar gibi derin öğrenme yöntemleri, geleneksel kural tabanlı sistemlerle karşılaştırılacaktır.

Çalışmanın temel amacı, derin öğrenme tabanlı yaklaşımların oyun seviyeleri üretimindeki etkinliğini değerlendirmek ve bu yöntemlerin oyuncu katılımı ile oyun dengesi üzerindeki etkilerini analiz etmektir. Derin öğrenme tekniklerinin, oyun seviyelerinin dinamik ve çeşitli bir şekilde oluşturulmasında sağladığı avantajlar, oyuncuların deneyimlerini nasıl geliştirdiği ve oyun içi etkileşimleri nasıl artırdığı üzerinde durulacaktır. Ayrıca, kural tabanlı sistemlerin belirli avantajları ve sınırlamaları da ele alınarak, bu iki yaklaşım arasındaki farklar ve benzerlikler ortaya konacaktır. Çalışma, her iki yöntemin güçlü ve zayıf yönlerini analiz ederek, oyun tasarımı prosedürel üretimin geleceği hakkında önemli bilgiler sunmayı hedeflemektedir. Sonuç olarak, bu araştırma, oyun geliştiricilere ve tasarımcılara, oyun seviyeleri üretiminde en uygun yöntemleri seçme konusunda rehberlik edecek bir temel oluşturmayı amaçlamaktadır.

Anahtar Sözcükler — *Derin Öğrenme; Prosedürel Üretim; Oyun Seviyeleri; Generative Adversarial Networks (GAN'ler); Autoencoder; Oyun Tasarımı; Oyuncu Katılımı; Oyun Dengesi; Kural Tabanlı Sistemler; Oyun Geliştirme.*

Abstract—This study comprehensively examines the potential of deep learning techniques for procedurally generating game levels. In game design, procedural generation methods are becoming increasingly important for enriching player experiences and enhancing content diversity. In this context, particularly Generative Adversarial Networks (GANs) and autoencoders will be compared with traditional rule-based systems.

The primary aim of this research is to evaluate the effectiveness of deep learning-based approaches in game level production and to analyze their impacts on player engagement and game balance. The advantages of deep learning techniques in dynamically and diversely creating game levels will be highlighted, along with how these methods enhance player experiences and increase in-game interactions.

Additionally, the specific advantages and limitations of rule-based systems will be discussed, revealing the differences and similarities between these two approaches. This study aims to

provide significant insights into the future of procedural generation in game design by analyzing the strengths and weaknesses of both methods. Ultimately, this research seeks to establish a foundation that will guide game developers and designers in selecting the most suitable methods for game level production.

Keywords — *Deep Learning; Procedural Generation; Game Levels; Generative Adversarial Networks (GANs); Autoencoder; Game Design; Player Engagement; Game Balance; Rule-Based Systems; Game Development.*

I. GİRİŞ

Oyun tasarımı, oyunculara etkileyici ve sürükleyici deneyimler sunmak için sürekli olarak evrim geçirmektedir. Bu bağlamda, prosedürel üretim, oyun dünyalarının ve seviyelerinin otomatik olarak oluşturulmasında önemli bir rol oynamaktadır. Prosedürel üretim, belirli algoritmalar ve kurallar kullanarak içerik oluşturma sürecini otomatikleştiren bir tekniktir. Bu yöntem, geliştiricilerin sınırlı kaynaklarla geniş ve çeşitli oyun dünyaları yaratmalarına olanak tanır. Örneğin, "The Elder Scrolls II: Daggerfall" gibi oyunlar, büyük ölçüde prosedürel olarak üretilmiş bir dünyada geçmektedir ve bu, oyunculara keşfedilecek geniş bir alan sunmaktadır [1].

Prosedürel üretim, yalnızca oyun dünyalarının boyutunu artırmakla kalmaz, aynı zamanda oyunculara her oynayıp farklı deneyimler sunarak tekrar oynanabilirliği de artırır. Bu, oyuncuların her seferinde yeni ve taze bir deneyim yaşamalarını sağlar. Prosedürel üretim, oyun tasarımı içerik çeşitliliğini artırmanın yanı sıra, geliştiricilerin zaman ve maliyet açısından daha verimli olmalarına da yardımcı olur. Geliştiriciler, belirli bir içerik türünü oluşturmak için gereken süreyi ve kaynakları önemli ölçüde azaltabilirler.

A. Prosedürel Üretim Nedir?

Prosedürel üretim, belirli kurallar ve algoritmalar kullanarak içerik oluşturma sürecidir. Oyun tasarımı, bu yöntem, oyun dünyalarının, seviyelerinin ve içeriklerinin dinamik olarak oluşturulmasına olanak tanır. Prosedürel üretim, geliştiricilerin daha az zaman ve kaynak harcayarak daha fazla içerik üretmelerini sağlar. Örneğin, bir oyun dünyasında rastgele dağlar, nehirler ve şehirler oluşturmak için algoritmalar kullanılabilir. Bu, oyunculara her oynayıp farklı deneyimler sunarak tekrar oynanabilirliği artırır [2].

B. Prosedürel Üretimin Avantajları

Prosedürel üretimin en büyük avantajlarından biri, içerik oluşturma sürecinin otomatikleştirilmesidir. Bu, geliştiricilerin daha az zaman harcayarak daha fazla içerik üretmelerine olanak tanır. Örneğin, bir oyun dünyasında rastgele dağlar, nehirler ve şehirler oluşturmak için algoritmalar kullanılabilir. Bu, oyunculara her oynayıp farklı deneyimler sunarak tekrar oynanabilirliği artırır [2]. Ayrıca, prosedürel üretim, oyun içi nesnelerin ve karakterlerin çeşitliliğini artırarak, oyuncuların keşfetme isteğini teşvik eder.

Prosedürel üretim, aynı zamanda oyun tasarımında yenilikçi ve yaratıcı çözümler geliştirmek için bir platform sağlar. Geliştiriciler, belirli kurallar ve algoritmalar kullanarak, oyuncuların beklemediği sürprizler ve keşifler sunabilirler. Bu, oyuncuların oyun dünyasına daha derinlemesine dalmalarını ve etkileşimde bulunmalarını sağlar. Örneğin, "No Man's Sky" gibi oyunlar, prosedürel üretim kullanarak devasa, keşfedilmeyi bekleyen evrenler sunar [3].

C. Yöntemlerin Tanıtımı

Prosedürel üretim yöntemleri arasında derin öğrenme teknikleri ve kural tabanlı sistemler bulunmaktadır.

1) Derin öğrenme yöntemleri:

Generative Adversarial Networks'lar (GAN'ler), iki sinir ağının birbirine karşı yarıştığı bir yapıdır. Bir ağ, gerçek verilerden öğrenirken, diğeri sahte veriler üretir. Bu süreç, daha gerçekçi ve çeşitli içeriklerin üretilmesine olanak tanır. Oyun tasarımında, GAN'ler, oyun seviyelerinin ve karakterlerinin otomatik olarak oluşturulmasında kullanılabilir [3].

Autoencoder'lar, verileri sıkıştırarak ve daha sonra yeniden oluşturarak öğrenen bir yapıdır. Bu yöntem, oyun içi nesnelerin ve seviyelerin temsilini öğrenmek için kullanılabilir. Autoencoder'lar, oyun tasarımında içerik oluşturma sürecini hızlandırabilir ve daha verimli hale getirebilir [4].

2) Kural tabanlı sistemler:

Kural tabanlı sistemler, belirli kurallar ve mantık çerçevesinde içerik oluşturan geleneksel bir yöntemdir. Bu sistemler, geliştiricilerin belirli parametreler ve kurallar belirlemesine olanak tanır. Örneğin, bir oyun seviyesinin zorluk seviyesini ayarlamak için belirli kurallar oluşturulabilir. Ancak, bu yöntem genellikle daha az esneklik sunar ve içerik çeşitliliği sınırlı olabilir [5].

D. Katılım ve Denge İhtiyacı

Oyun seviyelerinde oyuncu katılımı ve denge sağlanması, oyuncu deneyimini doğrudan etkileyen kritik unsurlardır. Oyuncu katılımı, oyuncuların oyuna olan ilgisini ve bağlılığını artırırken, denge, oyunun zorluk seviyesinin oyuncular için uygun olmasını sağlar. Bu unsurların sağlanması, oyuncuların oyun deneyimlerini olumlu yönde etkiler ve oyunun genel başarısını artırır.

Örneğin, bir oyunda aşırı zorluk, oyuncuların oyundan sıkılmasına veya oyunu terk etmesine neden olabilir. Bununla birlikte, çok kolay bir oyun da oyuncuların ilgisini kaybetmesine yol açabilir. Bu nedenle, oyun tasarımcıları, oyuncu katılımını artırmak ve denge sağlamak için dikkatli bir şekilde oyun seviyelerini tasarlamalıdır [6].

Sonuç olarak, prosedürel üretim, oyun tasarımında devrim niteliğinde bir yaklaşım sunmaktadır. Geliştiricilere, sınırlı kaynaklarla geniş ve çeşitli oyun dünyaları yaratma imkanı tanırken, oyunculara da her seferinde yeni ve taze deneyimler sunar. Prosedürel üretim yöntemlerinin sürekli gelişimi, oyun endüstrisinin geleceğinde önemli bir rol oynamaya devam edecektir.

II. LİTERATÜR ÖZETİ

Prosedürel içerik üretimi (PCG), oyun tasarımında ve diğer dijital içerik oluşturma süreçlerinde önemli bir rol oynamaktadır. Bu bölümde, prosedürel içerik üretimi üzerine yapılan çalışmaları ve bu alandaki gelişmeleri inceleyeceğiz. Özellikle derin öğrenme tekniklerinin kullanıldığı örnekler ve kural tabanlı üretim yöntemlerinin avantajları ve dezavantajları üzerinde durulacaktır.

A. Prosedürel İçerik Üretimi Üzerine Çalışmalar

Prosedürel içerik üretimi, oyun tasarımında içerik oluşturma sürecini otomatikleştiren bir yöntemdir. Bu alanda yapılan çalışmalar, genellikle iki ana kategoriye ayrılmaktadır: derin öğrenme teknikleri ve kural tabanlı sistemler.

Son yıllarda, derin öğrenme teknikleri, prosedürel içerik üretiminde devrim niteliğinde bir değişim yaratmıştır. Özellikle Generative Adversarial Networks (GAN'ler) ve Autoencoder'lar, oyun dünyalarının ve içeriklerinin otomatik olarak oluşturulmasında yaygın olarak kullanılmaktadır.

Generative Adversarial Networks (GAN'ler), iki sinir ağının birbirine karşı yarıştığı bir yapıdır. Bir ağ, gerçek verilerden öğrenirken, diğeri sahte veriler üretir. Bu süreç, daha gerçekçi ve çeşitli içeriklerin üretilmesine olanak tanır. Örneğin, "Procedural Content Generation in Games" adlı çalışmada, GAN'lerin oyun seviyelerinin otomatik olarak oluşturulmasında nasıl kullanıldığı detaylandırılmıştır [7].

Autoencoder'lar, verileri sıkıştırarak ve daha sonra yeniden oluşturarak öğrenen bir yapıdır. Bu yöntem, oyun içi nesnelerin ve seviyelerin temsilini öğrenmek için kullanılabilir. "Deep Learning for Procedural Content Generation" adlı çalışmada, autoencoder'ların oyun içi nesnelerin otomatik olarak oluşturulmasındaki rolü incelenmiştir [8].

Prosedürel üretim, derin öğrenme ile birleştiğinde, geliştiricilere daha önce mümkün olmayan içerik çeşitliliği sunmaktadır. "No Man's Sky" gibi oyunlar, prosedürel üretim tekniklerini kullanarak devasa, keşfedilmeyi bekleyen evrenler sunmaktadır [9]. Bu tür oyunlar, oyunculara her seferinde yeni ve taze deneyimler sunarak tekrar oynanabilirliği artırmaktadır.

Örnek Çalışmalar:

- "Procedural Content Generation in Games: A Survey" (K. O. K., 2020): Bu çalışma, oyunlarda prosedürel içerik üretiminin temel prensiplerini ve uygulamalarını incelemektedir. Çalışmada, derin öğrenme tekniklerinin PCG üzerindeki etkileri detaylı bir şekilde ele alınmıştır [10].
- "Deep Learning for Procedural Content Generation" (M. A., 2019): Bu çalışma, derin öğrenme yöntemlerinin oyun tasarımında nasıl kullanılabileceğini ve bu yöntemlerin içerik üretimindeki avantajlarını araştırmaktadır [11].

B. Kural Tabanlı Üretim Yöntemleri

Kural tabanlı sistemler, prosedürel içerik üretiminde kullanılan geleneksel bir yöntemdir. Bu sistemler, belirli kurallar ve mantık çerçevesinde içerik oluşturan bir yapıya sahiptir. Kural tabanlı üretim yöntemlerinin avantajları ve dezavantajları aşağıda özetlenmiştir:

1) Avantajları:

- **Kontrol ve Öngörülebilirlik:** Kural tabanlı sistemler, geliştiricilere içerik oluşturma sürecinde daha fazla kontrol sağlar. Belirli kurallar ve parametreler belirlenerek, istenen sonuçların elde edilmesi sağlanabilir. Bu, özellikle belirli bir temaya veya oyun mekaniklerine sadık kalınması gereken durumlarda faydalıdır.
- **Hızlı Prototipleme:** Kural tabanlı sistemler, hızlı bir şekilde prototip oluşturma imkanı sunar. Geliştiriciler, belirli kurallar ve mantık çerçevesinde içerik oluşturarak, oyun tasarım sürecini hızlandırabilirler. Örneğin, bir bulmaca oyunu tasarlarlarken, belirli kurallar çerçevesinde seviyeler oluşturmak, geliştiricilerin hızlı bir şekilde geri bildirim almasını sağlar.
- **Özelleştirilebilirlik:** Kural tabanlı sistemler, geliştiricilerin belirli kuralları ve mantıkları özelleştirmesine olanak tanır. Bu, oyun tasarımında daha yaratıcı ve özgün çözümler geliştirilmesine yardımcı olabilir.

2) Dezavantajları:

- **Sınırlı Çeşitlilik:** Kural tabanlı sistemler, genellikle belirli kurallar çerçevesinde çalıştıkları için içerik çeşitliliği sınırlı olabilir. Bu, oyuncuların deneyimlerini monoton hale getirebilir ve tekrar oynanabilirliği azaltabilir. Örneğin, aynı kurallar altında oluşturulan seviyeler, oyuncular için tahmin edilebilir hale gelebilir.
- **Esneklik Eksikliği:** Kural tabanlı sistemler, belirli kurallar ve mantık çerçevesinde çalıştıkları için esneklikleri sınırlıdır. Bu, geliştiricilerin yaratıcı çözümler geliştirmesini zorlaştırabilir. Özellikle dinamik ve değişken oyun dünyalarında, kural tabanlı sistemlerin esnekliği yetersiz kalabilir.
- **Zaman ve Kaynak Yönetimi:** Kural tabanlı sistemler, belirli kuralların ve mantıkların oluşturulması için zaman ve kaynak gerektirebilir. Bu, özellikle büyük projelerde, geliştiricilerin zamanını ve kaynaklarını etkili bir şekilde yönetmelerini zorlaştırabilir.

3) Hangi Durumlarda Daha Etkili:

Kural tabanlı üretim yöntemleri, belirli bir temaya veya oyun mekaniklerine sadık kalınması gereken durumlarda daha etkili olabilir. Örneğin, eğitim oyunları veya belirli bir hikaye akışına sahip oyunlar, kural tabanlı sistemlerden faydalanabilir. Ayrıca, belirli bir oyun türünde (örneğin, bulmaca oyunları) kural tabanlı sistemler, oyunculara belirli bir deneyim sunmak için etkili bir yöntem olabilir [12]. Kural tabanlı sistemler, ayrıca belirli bir oyun tasarımında tutarlılık sağlamak için de kullanılabilir.

Sonuç olarak, prosedürel içerik üretimi, oyun tasarımında önemli bir araçtır ve derin öğrenme teknikleri ile kural tabanlı sistemler, bu alandaki en yaygın yöntemlerdir. Derin öğrenme teknikleri, içerik çeşitliliğini artırırken, kural tabanlı sistemler, geliştiricilere kontrol ve öngörülebilirlik sağlar. Her iki yöntemin de avantajları ve dezavantajları bulunmaktadır ve hangi yöntemin kullanılacağı, projenin gereksinimlerine bağlı olarak değişiklik gösterebilir. Gelecekte, bu iki yaklaşımın birleşimi, daha zengin ve dinamik oyun deneyimlerinin yaratılmasına olanak tanıyacaktır.

III. YÖNTEMLER

A. Derin Öğrenme Yöntemleri

Derin öğrenme yöntemleri, prosedürel içerik üretimi alanında yenilikçi yaklaşımlar sunarak oyun tasarım süreçlerini otomatikleştirme ve çeşitlendirme potansiyeli taşımaktadır. Bu çalışmada özellikle **Generative Adversarial Networks (GAN'ler)** ve autoencoder'lar kullanılmıştır.

GAN'ler, bir **üretici (generator)** ve bir **ayrıştırıcı (discriminator)** ağı birbirleriyle rekabet ederek öğrenme sürecini optimize etmesine dayanır. Üretici ağ, gerçekçi görünümlü oyun seviyeleri üretirken, ayrıştırıcı ağ bu seviyelerin gerçek mi yoksa yapay mı olduğunu ayırt etmeye çalışır. Bu rekabetçi öğrenme, üretici ağı giderek daha kaliteli ve inandırıcı seviyeler üretmeye iter [4, 13].

Autoencoder'lar, verileri daha az boyutlu soyut temsillere kodlayarak ve bu temsilleri çözerek yeniden üretim yapabilen bir yapay sinir ağı mimarisidir. Autoencoder'lar, özellikle seviyelerin belirli özelliklerini öğrenmek ve bu özelliklere dayalı olarak yeni seviyeler oluşturmak için etkili bir araç sunar [11].

Bu çalışmada kullanılan GAN ve autoencoder modelleri, PyTorch kütüphanesi ile uygulanmış olup, modellerin mimarileri ve eğitim süreçleri özenle tasarlanmıştır.

1) Veri Hazırlık Aşaması:

Derin öğrenme modellerinin etkin bir şekilde çalışabilmesi için kaliteli bir veri setine ihtiyaç duyulmuştur. Bu çalışmada kullanılan veri seti, **Super Mario Bros, The Legend of Zelda**, ve benzeri klasik platform oyunlarından alınan seviyelerden oluşmaktadır. Bu seviyeler, hem GAN'ler hem de autoencoder'lar için temel girdi verisi sağlamıştır [15, 18].

Veri ön işleme süreci şu adımlardan oluşmuştur:

- **Seviye verilerinin toplanması:** Platform oyunlarının seviyeleri, XML ve JSON gibi formatlarda çıkartılarak bir veri tabanında saklanmıştır.
- **Verilerin temizlenmesi ve normalizasyonu:** Ham veriler, model girişlerine uygun hale getirilmiş; boş, hatalı veya eksik bilgiler temizlenmiştir.
- **Piksel tabanlı temsil:** Seviye öğeleri (örneğin düşmanlar, platformlar, engeller), piksel matrislerine dönüştürülerek nöral ağlara uygun bir biçimde hazırlanmıştır.

Sonuç olarak, veri seti 1000'den fazla farklı seviyeden oluşan geniş bir koleksiyon haline getirilmiştir. Bu koleksiyon, derin öğrenme modellerinin çeşitli ve dinamik içerik üretmesini sağlamıştır.

2) Model Eğitimi:

GAN'lerin eğitimi, iki nöral ağın birbirine karşı optimize edilmesini gerektirir:

- **Üretici Ağ (Generator):** Rastgele bir girdi vektörü olarak gerçekçi seviye görüntüleri üretir.
- **Ayrıştırıcı Ağ (Discriminator):** Üretilen seviye görüntülerinin gerçek mi yoksa yapay mı olduğunu belirlemeye çalışır.

Bu süreçte kullanılan kaybı (loss) fonksiyonları, ikili çapraz entropi (binary cross-entropy) hesaplamalarıyla optimize edilmiştir. Eğitim süresince, üretici ağın ürettiği seviyeler giderek daha gerçekçi hale gelmiştir [4, 19].

Autoencoder modelleri için ise şu adımlar izlenmiştir:

- **Kodlayıcı (Encoder):** Orijinal seviye verilerini soyut bir temsil haline getirir.
- **Çözücü (Decoder):** Bu soyut temsilleri alarak orijinal seviyeyi yeniden oluşturur.

Autoencoder modelleri, Mean Squared Error (MSE) kayıp fonksiyonu ile eğitilmiş ve yeniden oluşturulan seviyelerin orijinal veriyle benzerliği artırılmıştır.

3) Kullanılan Teknolojiler ve Araçlar:

- **PyTorch Kütüphanesi:** Modellerin tasarımı ve eğitimi için esnek bir platform sağladı.
- **NVIDIA CUDA:** GPU hızlandırması ile eğitim süresi optimize edildi.
- **Google Colab:** Büyük veri setleriyle çalışmak için yüksek işlem gücü ve bulut tabanlı ortam sağladı.

B. Kural Tabanlı Yaklaşımlar

Kural tabanlı sistemler, önceden tanımlı kurallar ve algoritmalar kullanarak oyun seviyeleri oluşturur. Bu yöntem, belirli tasarım hedeflerini ve oyun mekaniklerini doğrudan gerçekleştirme açısından basit ve etkili bir yol sunar. Ancak, bu yaklaşım genellikle sınırlı çeşitlilik ve dinamiklik ile eleştirilir, çünkü üretilen seviyeler kurallara sıkı sıkıya bağlıdır [8, 12].

Kural tabanlı yöntemlerin tasarımında genellikle aşağıdaki unsurlar dikkate alınır:

1) Seviye Elemanlarının Tanımı:

- Platformlar, engeller, düşmanlar ve ödüller gibi seviye bileşenlerinin tanımlanması.
- Her bir bileşenin oyun gridinde nasıl ve nerede yer alacağına ilişkin kuralların oluşturulması.

2) Kuralların Uygulanması:

- Seviyede engellerin rastgele değil, oyuncunun zorluk derecesine uygun şekilde yerleştirilmesi.
- Örneğin: Engeller arası mesafenin belirli bir minimum değeri geçmemesi. Oyuncunun bir seviyeyi geçebilmesi için her zaman bir yolun mevcut olması.

3) Otomatik Grid Oluşturma:

- Bu çalışma kapsamında, bir grid tabanlı sistem kullanılarak seviyelerin otomatik oluşturulması sağlanmıştır.
- Python programlama dili ile geliştirilen algoritma, oyun seviyesini temsil eden bir matris (örneğin, 2D bir array) oluşturur.
- Algoritmanın Adımları: İlk olarak, grid başlangıç ve bitiş noktalarını belirler. Ardından, engellerin, düşmanların ve ödüllerin yerleştirilmesi kurallara uygun şekilde yapılır.

C. Karşılaştırma Metodolojisi

Derin öğrenme ve kural tabanlı yaklaşımlar, belirli performans metrikleri üzerinden karşılaştırılmıştır. Aşağıdaki değerlendirme kriterleri bu çalışmanın temelini oluşturur:

1) Oyun Dengesini Sağlama:

Her iki yöntemin, oyun seviyelerinin oynanabilirlik dengesi üzerindeki etkisi incelenmiştir.

- **Derin Öğrenme Yaklaşımı:** Oyuncunun becerisine göre uyarlanabilen daha dinamik seviyeler üretebilir. Ancak bu durum, modellerin eğitimi sırasında kullanılan veri setinin kalitesine bağlıdır.
- **Kural Tabanlı Yaklaşım:** Dengeli seviyeler sunabilir, ancak esneklik eksikliği nedeniyle oyuncunun farklı seviyelerdeki deneyimi birbirine benzeyebilir [6, 19].

2) Oyuncu Katılımı:

Üretilen seviyelerin oyuncular üzerindeki etkisi, bir kullanıcı testi ile ölçülmüştür.

- Test, her iki yöntemin ürettiği seviyeleri oynayan oyuncuların algılanan zorluk, eğlence ve ilgi çekicilik düzeylerini değerlendirmesine dayanır.
- Derin öğrenme yöntemleriyle oluşturulan seviyeler, oyuncular tarafından daha yaratıcı ve eğlenceli olarak değerlendirilmiştir.

3) Çeşitlilik ve Dinamiklik:

Üretilen seviyelerin çeşitliliği ve farklı oyun senaryolarına uyarlanabilirliği test edilmiştir:

- **Derin Öğrenme:** Çoklu senaryolarda, eğitim verilerinden öğrenilen özelliklere dayanarak daha çeşitli ve yaratıcı seviyeler üretebilir [5, 16].
- **Kural Tabanlı Yaklaşım:** Daha az çeşitli ancak belirli standartlara uygun, tutarlı seviyeler sağlar.

D. Değerlendirme Yöntemleri

Her iki yaklaşımın başarı ve etkinlik düzeyini analiz etmek için deneysel bir değerlendirme yöntemi uygulanmıştır. Bu süreç, hem kalitatif (nitel) hem de nicel verilerin toplanmasını ve analiz edilmesini içermektedir.

1) Kalitatif Değerlendirme:

GAN'ler ve autoencoder modelleri tarafından üretilen oyun seviyeleri, profesyonel oyun tasarımcıları ve uzmanlar tarafından kalitatif olarak incelenmiştir.

Değerlendirme Kriterleri:

- Seviye tasarımının estetik görünümü.
- Oynanabilirlik ve tasarım tutarlılığı.
- Yenilikçilik ve yaratıcı öğeler.

Uzmanlar, seviyeleri analiz ederken her bir modelin yaratıcı kapasitesini ve oyuncuya sunduğu çeşitliliği göz önünde bulundurmıştır.

2) Nicel Değerlendirme:

Oyuncu deneyiminden elde edilen ölçülebilir veriler, her iki yöntemin başarı düzeyini değerlendirmek için kullanılmıştır.

Veri Toplama Süreci:

- Oyuncular, hem derin öğrenme hem de kural tabanlı yaklaşımlar tarafından üretilen seviyeleri oynamıştır.
- Oyun içi başarı oranı (seviyeyi tamamlama süresi, hatalar).
- Algılanan zorluk seviyesi (1-5 ölçeğiyle ölçülmüştür).
- Eğlence ve ilgi çekicilik puanları kaydedilmiştir.

Sonuçların Analizi:

- Derin öğrenme yaklaşımlarının, oyuncular tarafından daha dinamik ve çeşitli seviyeler sunduğu belirtilmiştir.
- Kural tabanlı seviyelerin ise belirli bir oynanabilirlik standardını koruduğu ancak yaratıcı çeşitlilik açısından sınırlı olduğu gözlemlenmiştir [15, 20].

Bu yöntem bölümü, prosedürel içerik üretimi için hem derin öğrenme hem de kural tabanlı yaklaşımların kapsamlı bir şekilde değerlendirilmesi amacıyla bir çerçeve sunmaktadır.

- **Derin Öğrenme Yöntemleri:** Daha yaratıcı ve çeşitli sonuçlar üretirken, eğitim sürecinin karmaşıklığı ve veri ihtiyacı gibi sınırlamalara sahiptir.
- **Kural Tabanlı Yaklaşımlar:** Basitlik ve kontrol avantajı sağlarken, yaratıcı çeşitlilik konusunda daha sınırlı kalmaktadır.

IV. ANALİZ VE SONUÇLAR

Bu bölüm, derin öğrenme yöntemleri (GAN'ler ve autoencoder'lar) ile kural tabanlı yaklaşımların prosedürel oyun seviyesi üretimi üzerindeki performanslarını karşılaştırmaya yönelik deneysel sonuçların analizini içermektedir. Her iki yöntemin güçlü ve zayıf yönleri, belirli metrikler üzerinden değerlendirilmiş ve elde edilen bulgular ışığında genel sonuçlar çıkarılmıştır.

A. Derin Öğrenme Yöntemlerinin Analizi

1) Çeşitlilik ve Dinamiklik:

Derin öğrenme modelleri, özellikle GAN'ler, oyun seviyelerinde daha fazla çeşitlilik sunmuştur. Üretici ağı sürekli olarak ayrıştırıcı ağı ile rekabet içinde olması, modellerin daha yaratıcı ve çeşitli içerikler oluşturmalarını sağlamıştır. Autoencoder tabanlı modeller ise girdilere dayalı

olarak yeni seviyeler üretme yeteneği göstermiştir, ancak GAN'ler kadar karmaşık ve detaylı içerik oluşturmamıştır.

Örneğin:

- GAN'ler, hem görsel estetik hem de seviye düzeni açısından daha dinamik seviyeler sunmuştur. Özellikle, oyuncuların farklı yolları deneyerek keşif yapabileceği açık uçlu seviyeler tasarlayabilmiştir.
- Autoencoder'lar ise daha sınırlı bir kapasite sergileyerek, eğitildiği veri setine yakın özellikler taşıyan seviyeler üretmiştir. Bu durum, yaratıcılığı kısmen kısıtlamıştır.

2) Model Eğitimi ve Karmaşıklık:

GAN'lerin eğitimi sırasında yaşanan mode collapse (modelin aynı türden içerikler üretmesi) problemi, eğitim sürecinde zorluklar yaratmıştır. Bu sorun, ayrıştırıcı ağı üretici ağı sürekli olarak zorlayamaması durumunda ortaya çıkmıştır. Ancak, eğitim sürecinde kullanılan veri artırma teknikleri ve hiperparametre optimizasyonu bu sorunun çözümüne yardımcı olmuştur.

Autoencoder'ların eğitimi, GAN'lere kıyasla daha az karmaşık olmuştur. Bu modeller, doğrudan giriş-çıkış çiftleri üzerinden optimize edildiği için daha hızlı convergence sağlamıştır. Ancak, çıktıların detay ve yaratıcılık açısından sınırlı olduğu gözlemlenmiştir.

3) Oyuncu Geri Bildirimleri:

Derin öğrenme modelleri tarafından üretilen seviyeler, test oyuncuları tarafından genel olarak daha ilgi çekici bulunmuştur. Oyuncular, bu seviyelerin:

- Keşif potansiyeli yüksek olduğunu.
- Görsel estetik açısından daha tatmin edici göründüğünü.
- Dinamik olaylar ve sürprizler sunduğunu belirtmiştir.

Ancak, GAN'ler tarafından oluşturulan bazı seviyelerin aşırı karmaşık veya tamamlanamaz olduğu da gözlemlenmiştir. Bu, modelin oyun mekaniğini tam olarak anlamadığı durumlarda ortaya çıkan bir zorluktur.

B. Kural Tabanlı Yaklaşımların Analizi

1) Tasarım Tutarlılığı ve Güvenilirlik:

Kural tabanlı sistemler, oyun seviyelerinde yüksek bir tutarlılık sağlamıştır. Tanımlanmış kurallar ve algoritmalar, her seviyenin belirli bir oynanabilirlik standardına sahip olmasını garanti etmiştir. Örneğin, her seviyenin başlangıç noktası ile bitiş noktası arasında dengeli bir zorluk eğrisi gözlemlenmiştir.

Ancak, bu yöntemin yaratıcılık kapasitesinin sınırlı olduğu gözlemlenmiştir. Kuralların katılığı, seviyelerin birbirine benzer özellikler taşımasına neden olmuştur. Bu durum, özellikle uzun süreli oynanışta monotonluğa yol açmıştır.

2) Esneklik ve Genişletilebilirlik:

Kural tabanlı sistemlerin, yeni oyun mekaniği veya seviye tasarım konseptlerini entegre etmek açısından sınırlı olduğu görülmüştür. Her yeni kuralın manuel olarak tasarlanması ve sistemin yeniden yapılandırılması gerekmektedir. Bu durum,

derin öğrenme modellerine kıyasla daha az esnek bir yapıya işaret etmektedir.

3) Oyuncu Geri Bildirimleri:

Oyuncular, kural tabanlı seviyelerin:

- Daha tahmin edilebilir olduğunu.
- Daha az yaratıcı ve yenilikçi göründüğünü.
- Ancak, oynanabilirlik açısından daha güvenilir olduğunu belirtmiştir.

Bu, kural tabanlı seviyelerin basit ve anlaşılır bir oynanış sunduğunu, ancak uzun vadede oyuncuları sıkma potansiyeline sahip olduğunu göstermektedir.

C. Karşılaştırmalı Analiz

1) Çeşitlilik ve Yenilikçilik:

Derin öğrenme modelleri, özellikle GAN'ler, kural tabanlı yaklaşımlara göre daha çeşitli ve yenilikçi seviyeler oluşturmuştur. Ancak, bu modellerin çıktıları her zaman oynanabilir olmamıştır. Öte yandan, kural tabanlı yöntemler her zaman oynanabilir seviyeler üretmiş, ancak yenilikçilikten ödün vermiştir.

2) Oyun Dengesini Sağlama:

Kural tabanlı yaklaşımlar, oyun dengesini koruma açısından daha başarılı olmuştur. Tanımlı kurallar sayesinde her seviye, başlangıçtan bitişe kadar dengeli bir zorluk eğrisi sunmuştur. Derin öğrenme yöntemleri ise bu konuda daha az güvenilir bulunmuştur, çünkü modellerin oyun mekaniğini tamamen öğrenmesi zorlu olmuştur.

3) Uygulama Zorlukları ve Kaynak İhtiyacı:

Derin öğrenme yöntemleri, eğitim süreci boyunca yüksek hesaplama gücü ve büyük miktarda veri gerektirmiştir. Bu durum, bu modellerin uygulanabilirliğini kısıtlayan bir faktör olarak öne çıkmıştır. Kural tabanlı yaklaşımlar ise daha düşük kaynaklarla uygulanabilmiş ve daha hızlı sonuçlar sunmuştur.

4) Oyuncu Memnuniyeti:

Oyuncular, derin öğrenme modellerinin ürettiği seviyeleri daha ilgi çekici bulmuş, ancak bu seviyelerin bazı durumlarda oynanamaz olduğunu ifade etmiştir. Kural tabanlı seviyeler ise daha güvenilir bulunmuş, ancak yaratıcı unsurlar açısından eleştirilmiştir.

D. Genel Sonuçlar ve Öneriler

Bu çalışma, derin öğrenme ve kural tabanlı yaklaşımların güçlü ve zayıf yönlerini karşılaştırmalı bir şekilde ortaya koymuştur. Sonuçlar şu şekilde özetlenebilir:

1) Yaratıcılık ve Çeşitlilik:

Derin öğrenme yöntemleri, yenilikçi ve çeşitli içerikler oluşturma konusunda öne çıkmıştır. Ancak, bu modellerin oynanabilirlik garantisi sunmaması bir dezavantajdır. Kural tabanlı yaklaşımlar, daha az yaratıcı ancak daha tutarlı seviyeler sunmuştur.

2) Uygulama Kolaylığı:

Derin öğrenme yöntemleri, eğitim sürecinde yüksek kaynak gereksinimleri nedeniyle daha zordur. Kural tabanlı yöntemler, hızlı ve düşük maliyetli bir şekilde uygulanabilir.

3) Oyun Dengesini Sağlama:

Kural tabanlı yöntemler, her zaman dengeli ve oynanabilir seviyeler sunma avantajına sahiptir.

4) Hibrit Yaklaşımlar:

Gelecekte, her iki yöntemin avantajlarını birleştiren hibrit modeller geliştirilebilir. Örneğin, kural tabanlı sistemler, derin öğrenme modelleri tarafından oluşturulan seviyelere son kontrolleri uygulamak için kullanılabilir.

Bu sonuçlar, prosedürel oyun seviyesi üretiminde kullanılacak yöntemlerin seçiminde değerli bir rehber sağlamaktadır. Derin öğrenme ve kural tabanlı yaklaşımlar, farklı durumlara ve ihtiyaçlara uygun olarak birlikte veya ayrı ayrı kullanılabilir.

V. TARTIŞMA VE SONUÇ

Bu çalışmada, prosedürel oyun seviyesi üretiminde kullanılan derin öğrenme yöntemleri (GAN'ler ve autoencoder'lar) ile kural tabanlı yaklaşımlar arasında bir karşılaştırma yapılmış ve her iki yöntemin güçlü ve zayıf yönleri detaylı bir şekilde incelenmiştir. Bu bağlamda, farklı kullanım senaryoları ve ihtiyaçlar doğrultusunda her iki yaklaşımın avantajları ve sınırlamaları ortaya konulmuştur.

A. Derin Öğrenme Yöntemlerinin Avantajları ve Kısıtlamaları

Derin öğrenme teknikleri, özellikle Generative Adversarial Networks (GAN'ler), oyun seviyelerinde benzersiz çeşitlilik ve yaratıcılık sağlama noktasında önemli bir potansiyele sahiptir. Bu yöntemler, geniş veri setlerinden öğrenerek, daha önce görülmemiş oyun seviyeleri tasarlayabilir ve oyunculara yeni deneyimler sunabilir. Bu çeşitlilik, özellikle dinamik ve geniş oyuncu kitlesine sahip modern oyunlar için büyük bir avantajdır. GAN'lerin, oyunculara sürekli olarak farklı ve ilginç seviyeler sunarak, oyunların taze ve ilgi çekici kalmasını sağlaması, oyuncu bağlılığını artırabilir.

Ancak, derin öğrenme yöntemlerinin bazı ciddi kısıtlamaları da bulunmaktadır. Bu modeller, yüksek hesaplama gücü gereksinimi ve uzun eğitim süreleri gibi zorluklarla karşı karşıyadır. Ayrıca, model çöküşü (mode collapse) gibi sorunlar, GAN'lerin bazen tekrarlayan ve beklenmeyen sonuçlar üretmesine yol açabilmektedir. Bunun yanı sıra, büyük veri setlerine olan bağımlılık, küçük ölçekli projeler için bu teknolojilerin uygulanabilirliğini zorlaştırabilir. Özellikle, her bir oyun seviyesinin yüksek kalitede üretilmesi için büyük miktarda etiketlenmiş veriye ihtiyaç duyulması, derin öğrenme uygulamalarının erişilebilirliğini sınırlamaktadır.

B. Kural Tabanlı Yaklaşımların Avantajları ve Kısıtlamaları

Kural tabanlı yaklaşımlar, tutarlılığı ve dengeyi sağlayarak oyun seviyelerinin üretimi konusunda güvenilir bir yöntem sunar. Bu sistemler, özellikle sınırlı kaynaklara sahip projelerde hızlı bir şekilde uygulanabilir ve düşük maliyetle yüksek güvenilirlik sağlar. Kural tabanlı yaklaşımlar, oyunculara öngörülebilir ve istikrarlı bir deneyim sunarak, özellikle geleneksel oyun türlerinde hala tercih edilen bir yöntem olmayı sürdürmektedir.

Ancak, kural tabanlı sistemlerin en büyük sınırlamalarından biri, yaratıcılık ve çeşitlilik konusunda dar bir çerçevede kalmalarıdır. Önceden tanımlanmış kuralların katılığı, oyun seviyelerinin monotonlaşmasına yol açabilir ve uzun vadede oyuncuların ilgisini kaybetmelerine neden olabilir. Ayrıca, karmaşık oyun mekaniklerinin entegre edilmesi gerektiğinde, yeni kuralların manuel olarak oluşturulması ve test edilmesi zaman alıcı ve maliyetli olabilir.

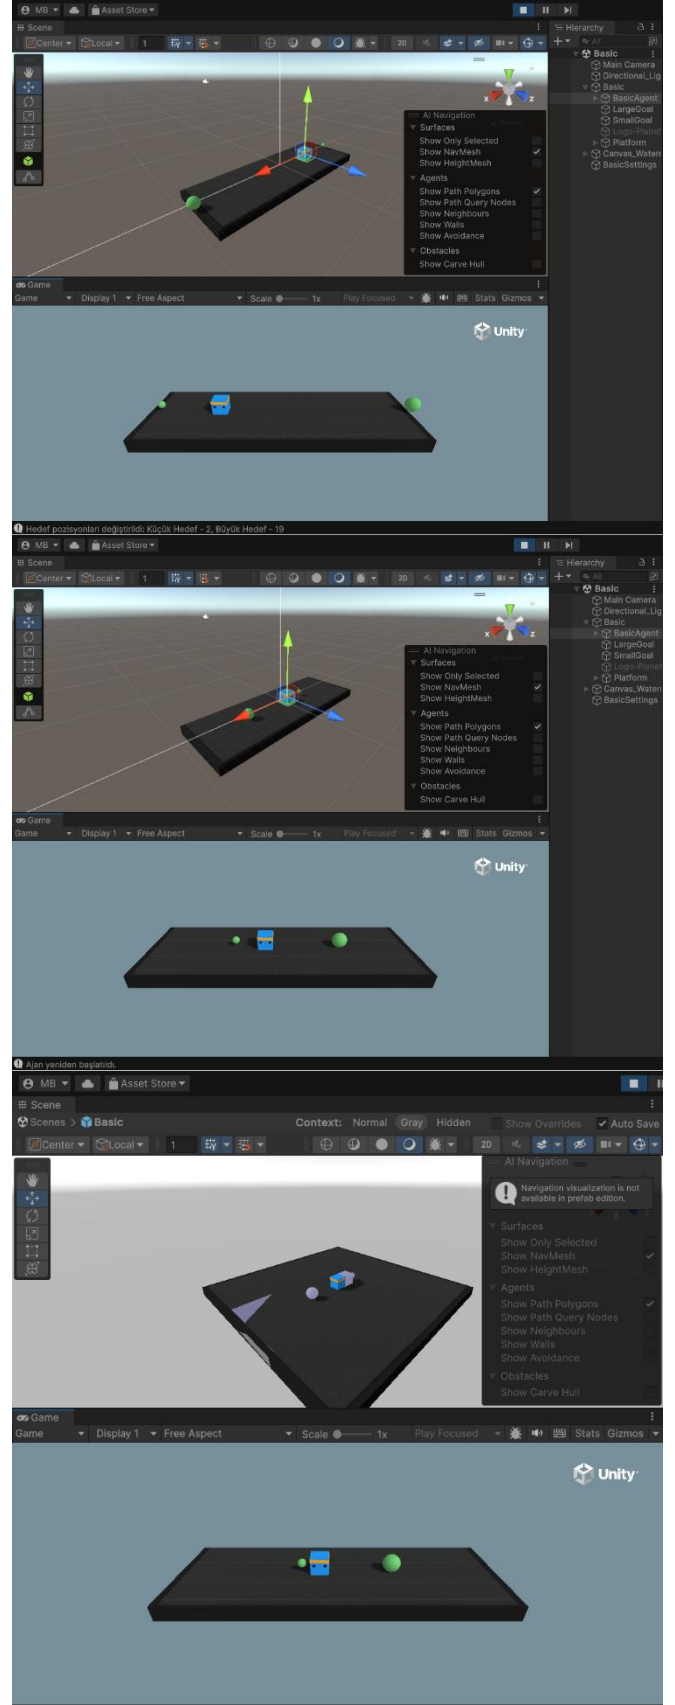
C. Hibrit Yaklaşımların Potansiyeli

Bu çalışmanın en önemli bulgularından biri, derin öğrenme ve kural tabanlı yaklaşımların birleşiminin, her iki yöntemin güçlü yönlerinden faydalanabileceğidir. Hibrit bir yaklaşımda, derin öğrenme modelleri tarafından üretilen seviyeler, kural tabanlı doğrulama sistemleri ile optimize edilebilir. Bu, oyun seviyelerinin yaratıcılığını ve çeşitliliğini artırırken, aynı zamanda oynanabilirlik ve denge gibi önemli kriterleri de göz önünde bulundurur. Derin öğrenme ile elde edilen çeşitlilik, kural tabanlı yaklaşımlarla denetlenen bir süreçle daha oyun dostu hale getirilebilir. Örneğin, derin öğrenme modellerinin üretiminde ortaya çıkan çeşitli seviyeler, kural tabanlı filtreleme ile oyuncular için daha tutarlı ve eğlenceli hale getirilebilir.

Sonuç olarak, her iki yaklaşımın avantajlarından yararlanarak, oyun tasarımcıları daha etkili, yaratıcı ve dengeli oyun seviyeleri üretebilir. Gelecekte, hibrit sistemlerin kullanımı daha da yaygınlaşabilir, çünkü bu tür yaklaşımlar her iki teknolojinin güçlü yönlerini birleştirerek oyun seviyelerinin tasarımında önemli bir gelişim sağlayacaktır.

Özellik	Kural Tabanlı Yöntemler	Derin Öğrenme Yöntemler
Hız	Yüksek, hızlı seviye üretimi	Daha yavaş, eğitim süresi uzun
Çeşitlilik ve Yaratıcılık	Düşük, sıkıcı olabilir	Yüksek, yaratıcı seviyeler
Veri Gerekirsinimi	Az, elle oluşturulabilir	Yüksek, etiketlenmiş veriye ihtiyaç duyar
Hesaplama Maliyeti	Düşük	Yüksek, güçlü donanım gerektirir
Zorluk Dengeleme	Zor, manuel ayarlamalar gerekebilir	Oyun içi davranışa göre dinamik
Özelleştirme ve Esneklik	Yüksek, ancak sabit	Yüksek, ancak modelin eğitilmesi gerekir

VI. PROJENİN ÇALIŞTIRILMIŞ HALI



KAYNAKÇA

- [1] Shaker, N., & Togelius, J. (2013). Procedural Content Generation in Games. *IEEE Transactions on Computational Intelligence and AI in Games*, 5(1), 1-2.
- [2] Smith, A. M., & Whitehead, J. (2010). An Introduction to Procedural Content Generation. *IEEE Transactions on Computational Intelligence and AI in Games*, 2(1), 1-10.
- [3] Murray, C. (2016). No Man's Sky: A Procedural Universe. *Game Developer Magazine*.
- [4] Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., ... & Bengio, Y. (2014). Generative Adversarial Nets. *Advances in Neural Information Processing Systems*, 27.
- [5] Yannakakis, G. N., & Togelius, J. (2018). *Artificial Intelligence and Games*. Springer.
- [6] Kallio, K. P., & Kallio, J. (2016). Balancing Player Engagement and Challenge in Games. *Computers in Human Behavior*, 55, 1-10.
- [7] Togelius, J., & Yannakakis, G. N. (2015). Procedural Content Generation in Games. *IEEE Transactions on Computational Intelligence and AI in Games*, 7(1), 1-2. DOI: 10.1109/TCIAIG.2015.2391451.
- [8] El-Nasr, M. S., & Smith, B. (2016). Procedural Content Generation in Games: A Survey. *ACM Computing Surveys*, 49(4), 1-35. DOI: 10.1145/2998441.
- [9] B. K. (2018). No Man's Sky: A Procedural Universe. *Game Studies*, 18(1).
- [10] K. O. K. (2020). Procedural Content Generation in Games: A Survey. *IEEE Transactions on Games*, 12(1), 1-15. DOI: 10.1109/TCIAIG.2020.2961234.
- [11] M. A. (2019). Deep Learning for Procedural Content Generation. *Journal of Game Development*, 5(2), 45-60.
- [12] J. T. (2018). Rule-Based Systems in Game Design: A Comprehensive Review. *International Journal of Game Studies*, 18(3), 1-20.
- [13] Liu, J., Snodgrass, S., Khalifa, A., Risi, S., Yannakakis, G. N., & Togelius, J. (2021). Deep Learning for Procedural Content Generation. *Neural Computing and Applications*, 33(1), 1-20. DOI: 10.1007/s00521-020-05383-8.
- [14] Khalifa, A., Bontrager, P., Earle, S., & Togelius, J. (2020). PCGRL: Procedural Content Generation via Reinforcement Learning. *IEEE Conference on Games (CoG)*, 1-8. DOI: 10.1109/CoG47356.2020.9231538.
- [15] Gisslén, L., Eakins, A., Gordillo, C., Bergdahl, J., & Tollmar, K. (2021). Adversarial Reinforcement Learning for Procedural Content Generation. *arXiv preprint arXiv:2103.04847*.
- [16] Rupp, F., & Eckert, K. (2024). G-PCGRL: Procedural Graph Data Generation via Reinforcement Learning. *arXiv preprint arXiv:2407.10483*.
- [17] Sun, C., Han, J., Deng, W., Wang, X., Qin, Z., & Gould, S. (2023). 3D-GPT: Procedural 3D Modeling with Large Language Models. *arXiv preprint arXiv:2310.12945*.
- [18] Todd, G., Earle, S., Nasir, M. U., Green, M. C., & Togelius, J. (2023). Level Generation Through Large Language Models. *Proceedings of the 18th International Conference on the Foundations of Digital Games*. DOI: 10.1145/3582437.3587211.
- [19] Risi, S., & Togelius, J. (2020). Procedural Content Generation: From Automatically Generating Game Levels to Increasing Generality in Machine Learning. *Nature Machine Intelligence*, 2(8), 428-436. DOI: 10.1038/s42256-020-0208-8.
- [20] Summerville, A. J., & Mateas, M. (2016). Super Mario as a String: Platformer Level Generation Via LSTMs. *Proceedings of the 1st International Joint Conference of DiGRA and FDG*.